

שאלה 3

סעיף 1) כיוון ראשון: פונק' PMF כאשר $k=2$ תהיה בהינתן סט אימון $S = \{(x_i, y_i)\}_{i=1}^m$, כאשר

$$P_w(Y_i = 2|x_i) = \frac{e^{w_2^T x_i}}{e^{w_1^T x_i} + e^{w_2^T x_i}} = p_2, \quad P_w(Y_i = 1|x_i) = \frac{e^{w_1^T x_i}}{e^{w_1^T x_i} + e^{w_2^T x_i}} = p_1, \quad y_i \in \{1, 2\}$$

$$, \quad p_1 = \frac{e^{w^T x_i}}{e^{w^T x_i} + e^0} = \frac{e^{w^T x_i}}{e^{w^T x_i} + 1} := p \quad \text{נגדיר } w_1 = w, \quad w_2 = 0 \quad \text{ואז מתקיים: } p$$

$$.p_2 = \frac{e^0}{e^{w^T x_i} + e^0} = \frac{1}{e^{w^T x_i} + 1} := 1 - p$$

כיוון שני: ניקח $w = w_1 - w_2$, ואז פונק' PMF במקרה הבינארי היא:

$$P_w(Y_i = 1|x_i) = \frac{e^{w^T x_i}}{e^{w^T x_i} + 1} = \frac{e^{w_1^T x_i - w_2^T x_i}}{e^{(w_1^T x_i - w_2^T x_i)} + 1} = \frac{\frac{e^{w_1^T x_i}}{e^{w_2^T x_i}}}{\frac{e^{w_1^T x_i}}{e^{w_2^T x_i}} + \frac{e^{w_2^T x_i}}{e^{w_2^T x_i}}} =$$

$$= \frac{\frac{e^{w_1^T x_i}}{e^{w_2^T x_i}}}{\frac{e^{w_1^T x_i} + e^{w_2^T x_i}}{e^{w_2^T x_i}}} = * \frac{e^{w_1^T x_i}}{e^{w_1^T x_i} + e^{w_2^T x_i}} = p_1$$

$$1 - p_1 = 1 - \frac{e^{w_1^T x_i}}{e^{w_1^T x_i} + e^{w_2^T x_i}} = \frac{e^{w_1^T x_i} + e^{w_2^T x_i} - e^{w_1^T x_i}}{e^{w_1^T x_i} + e^{w_2^T x_i}} = \frac{e^{w_2^T x_i}}{e^{w_1^T x_i} + e^{w_2^T x_i}}$$

*המכנה של המונה והמכנה של המכנה מצטמצמים

המעבר האחרון נובע מההגדרה של p_i , סימון לפונק' PMF במקרה הבידי.

סעיף 2) נמצא את ה-w שממקסם את הפונקציה:

$$\begin{aligned}\sum_{i=1}^m \log(P_w(Y_i = y_i|x_i)) &= \sum_{i=1}^m \log\left(\frac{e^{w_{y_i}^T x_i}}{\sum_{j=1}^k e^{w_{y_j}^T x_i}}\right) = \\ &= \sum_{i=1}^m \left(\log(e^{w_{y_i}^T x_i}) - \log\left(\sum_{j=1}^k e^{w_{y_j}^T x_i}\right) \right) = \sum_{i=1}^m \left(w_{y_i}^T x_i - \log\left(\sum_{j=1}^k e^{w_{y_j}^T x_i}\right) \right) = \ell_s(w)\end{aligned}$$

נעשה זאת באמצעות גזירה והשוואה לאפס:

$$\begin{aligned}\frac{\partial}{\partial w_k} \ell_s(w) &= \sum_{i=1}^m \left(I\{y_i = k\} * x_i - \frac{x_i e^{w_k^T x_i}}{\sum_{j=1}^k e^{w_j^T x_i}} \right) = \\ &= \sum_{i=1}^m I\{y_i = k\} * x_i - \sum_{i=1}^m \frac{e^{w_k^T x_i}}{\sum_{j=1}^k e^{w_j^T x_i}} * x_i = 0\end{aligned}$$

בהרצאה ראינו כי אם נגזור את פונקציית הלוג ביחס ל-w ונשווה לאפס נמצא מקסימום גלובלי. בתרגיל זה יש k איברי w, ולכן נגזור בנגזרות חלקיות ונגדיר אינדיקטור עבור הנגזרת של ה-w ה-k-י. נשים לב שבביטוי הימני בשורה שסומנה ב-*, מאחר ואנחנו גוזרים לפי נגזרת חלקית, כל הביטויים התלויים ב-w_i כאשר i ≠ k נופלים בגזירה ואנו נשארים רק עם הביטויים הגזורים שהיו תלויים לפני כן ב-w_k.

$$\Rightarrow \sum_{i=1}^m I\{y_i = k\} * x_i = \sum_{i=1}^m \left(\frac{e^{w_k^T x_i}}{\sum_{j=1}^k e^{w_j^T x_i}} \right) x_i$$

וזו ה-moment matching.

סעיף 3)

חלק a:

נשים לב כי במulticlass logisitic regression בהינתן וקטור פיצ'רים x_i , ההסתברות שהלייבל y_i הוא k היא p_{ik} , כאשר i מתייחס לדוגמה ה- k וה- k מתייחס למחלקה ה- k כלומר:

$$P(Y_i = k | x_i) = p_{ik} = \frac{e^{w_k^T x_i}}{\sum_{j=1}^K e^{w_j^T x_i}}, \quad w_1, \dots, w_K \in \mathbb{R}^d$$

שהרגרסיה הלוגיסטית מתמודדת איתה - במקרה הזה 3 מחלקות.

חלק b:

מאחר שמשוואת הרגרסיה הלוגיסטית מכילה מכפלה פנימית בין w לבין וקטור הפיצ'רים x ובנוסף איבר bias,

נוכל להחליף את הכתיב $w_k^T x_i + b$ בכתיב המקוצר $\tilde{w}_k^T \tilde{x}_i$ כאשר $\tilde{w}_k = (b, w_k)$, $\tilde{x}_i = (1, x_i)$ כלומר נוסיף כניסה שלישית לווקטורים הללו, ל- x נוסיף את הכניסה 1 על מנת שתכפול את הכניסה ב- w ששווה לערכו של איבר ה-bias. בשאלה נתונים וקטורי פיצ'רים עם שתי כניסות ווקטורי w עם 3 כניסות, לכן כל שנותר הוא להוסיף לכל וקטור פיצ'רים את הכניסה המכילה את הערך 1 כאשר נכפיל בינו לבין וקטור w .

חלק c:

עבור הווקטור x_1 :

$$\begin{aligned} \sum_{j=1}^3 e^{w_j^T x_1} &= e^{(8, -2.5, 2)^T (1, 1, 8)} + e^{(2, 0.5, -1.5)^T (1, 1, 8)} + e^{(-10, 2, -0.5)^T (1, 1, 8)} = \\ &= 21.7 \cdot 10^8 + 0.000075 + 0.000006 = 21.7 \cdot 10^8 \end{aligned}$$

$$\begin{aligned} \Rightarrow P(Y_1 = 0 | x_1) &= \frac{e^{w_1^T x_1}}{\sum_{j=1}^3 e^{w_j^T x_1}} = \frac{21.7 \cdot 10^8}{21.7 \cdot 10^8} \approx 1 \\ \Rightarrow P(Y_1 = 1 | x_1) &= \frac{e^{w_2^T x_1}}{\sum_{j=1}^3 e^{w_j^T x_1}} = \frac{0.000075}{21.7 \cdot 10^8} \approx 0 \\ \Rightarrow P(Y_1 = 2 | x_1) &= \frac{e^{w_3^T x_1}}{\sum_{j=1}^3 e^{w_j^T x_1}} = \frac{0.000006}{21.7 \cdot 10^8} \approx 0 \end{aligned}$$

נבחר את הלייבל 0 להיות הפרדיקציה של x_1 .

עבור הווקטור x_2 :

$$\begin{aligned} \sum_{j=1}^3 e^{w_j^T x_2} &= e^{(8, -2.5, 2)^T (1, 6, -2)} + e^{(2, 0.5, -1.5)^T (1, 6, -2)} + e^{(-10, 2, -0.5)^T (1, 6, -2)} = \\ &= 0.000017 + 2980.958 + 20.0855 = 3001.04 \end{aligned}$$

$$\Rightarrow P(Y_2 = 0|x_2) = \frac{e^{w_1^T x_1}}{\sum_{j=1}^3 e^{w_j^T x_1}} = \frac{0.000017}{3001.04} = 5.6 \cdot 10^{-9} \approx 0$$

$$\Rightarrow P(Y_2 = 1|x_2) = \frac{e^{w_2^T x_1}}{\sum_{j=1}^3 e^{w_j^T x_1}} = \frac{2980.958}{3001.04} = 0.9933$$

$$\Rightarrow P(Y_2 = 2|x_2) = \frac{e^{w_3^T x_1}}{\sum_{j=1}^3 e^{w_j^T x_1}} = \frac{20.0855}{3001.04} = 0.0067$$

נבחר את הלייבל 1 להיות הפרדיקציה של x_2 .

עבור הווקטור x_3 :

$$\begin{aligned} P(Y_3 = 0|x_3) &= p_{31} = \frac{e^{w_1^T x_3}}{\sum_{j=1}^3 e^{w_k^T x_i}} = \\ &= \frac{e^{8 \cdot 1 + (-2.5 \cdot (12)) + 2 \cdot 4}}{e^{8 \cdot 1 + (-2.5 \cdot (12)) + 2 \cdot 4} + e^{2 \cdot 1 + (0.5 \cdot (12)) + (-1.5) \cdot 4} + e^{-10 \cdot 1 + (2 \cdot (12)) + (-0.5) \cdot 4}} \\ &= \frac{e^{-14}}{e^{-14} + e^2 + e^{12}} = 5.108 \cdot 10^{-12} \approx 0 \end{aligned}$$

$$P(Y_3 = 1|x_3) = p_{32} = \frac{e^{w_2^T x_3}}{\sum_{j=1}^3 e^{w_k^T x_i}} = \frac{e^2}{e^{-14} + e^2 + e^{12}} = 4.539 \cdot 10^{-5}$$

$$P(Y_3 = 2|x_3) = p_{33} = \frac{e^{w_3^T x_3}}{\sum_{j=1}^3 e^{w_k^T x_i}} = \frac{e^{12}}{e^{-14} + e^2 + e^{12}} \approx 1$$

לסיכום עבור x_3 נבחר את הלייבל 2 להיות הפרדיקציה של x_3 .

